

Содержание

1	Введение	4
2	Обзор литературы	4
3	Постановка задачи	4
4	Основные концепции	4
4.1	GenPhys-подход	4
4.2	Генеративные модели PFGM, EFM and IFM	9
4.3	Потенциал Юкавы	9
5	Генеративная модель на основе потенциала Юкавы	9
6	Результаты вычислительных экспериментов	9
7	Результаты	9
	Список литературы	9

Аннотация

Физические концепции часто вдохновляют на создание новых алгоритмов машинного обучения. В частности, в генеративном моделировании в настоящее время именно такие модели являются state-of-the-art результатами. В данной работе недавно опубликованные работы генеративных моделей на основе электростатики расширяются на другую физическую концепцию - взаимодействие Юкавы. Особенности потенциала Юкавы позволяют давать лучшее качество алгоритмов генеративного моделирования и задач переноса домена.

Ключевые слова: генеративное моделирование, задача переноса домена, физика в ИИ, потенциал Юкавы, электростатика.

1 Введение

2 Обзор литературы

3 Постановка задачи

4 Основные концепции

4.1 GenPhys-подход

Главная идея

В статье [1] рассматривается семейство генеративных моделей **GenPhys** — generative models from physical processes, вдохновленных физикой и предлагается общий подход к созданию новых генеративных моделей на основе физики. Идея состоит в том, что физический процесс задается дифференциальным уравнением в частных производных (УрЧП или PDE), а непрерывная генеративная модель задается потоком плотности. Если PDE можно переписать как поток плотности, причем этот поток постепенно сглаживает исходное распределение данных, то обратная динамика может генерировать новые объекты из простого prior-распределения. Главный вопрос, который ставят авторы в этой статье: какие уравнения математической физики могут задавать полезные генеративные модели?

Генеративная модель как поток плотности

Пусть данные имеют распределение $p_{\text{data}}(x)$, где $x \in \mathbb{R}^N$. Непрерывная динамика частиц

$$\frac{dx}{dt} = v(x, t)$$

индуцирует эволюцию плотности $p(x, t)$:

$$\frac{\partial p(x, t)}{\partial t} + \nabla \cdot (p(x, t)v(x, t)) = 0.$$

Это уравнение непрерывности из физики: масса сохраняется, а поле скоростей v переносит плотность. В генеративной постановке forward-процесс должен переводить сложное распределение данных $p(x, 0) = p_{\text{data}}(x)$ в более простое распределение $p(x, T) = p_{\text{prior}}(x)$. Тогда для генерации можно взять $x(T) \sim p_{\text{prior}}$ и численно проинтегрировать ОДУ назад

по времени.

Для учета начального условия можно записать поток плотности с источником:

$$\hat{M}(p, v, R) \equiv \frac{\partial p}{\partial t} + \nabla \cdot (pv) - R = p_{\text{data}}(x)\delta(t).$$

Как PDE превращается в GenPhys

Физическое уравнение в общем виде записывается следующим образом:

$$\hat{L}\varphi \equiv F(\varphi, \varphi_t, \varphi_{tt}, \nabla\varphi, \nabla^2\varphi, \dots) = f(x, t),$$

где $\varphi(x, t)$ — физическое поле. Для линейных PDE решение удобно выражать через функцию Грина:

$$\varphi(x, t) = \int G(x, t; x') p_{\text{data}}(x') \, d^N x', \quad \hat{L}G(x, t; x') = \delta(x - x')\delta(t).$$

Алгоритм GenPhys можно записать так.

1. Выбрать физическое PDE $\hat{L}\varphi = 0$ и добавить источник $f(x, t) = p_{\text{data}}(x)\delta(t)$.
2. Переписать PDE в форме потока плотности:

$$\frac{\partial p}{\partial t} + \nabla \cdot (pv) - R = p_{\text{data}}(x)\delta(t),$$

где $p = p(\varphi, \varphi_t, \nabla\varphi, \dots)$, $v = v(\varphi, \varphi_t, \nabla\varphi, \dots)$, $R = R(\varphi, \varphi_t, \nabla\varphi, \dots)$.

3. Решить PDE, например через функцию Грина, и получить явные выражения для $p(x, t)$, $v(x, t)$ и $R(x, t)$.
4. Обучить нейросеть $s_\theta(x, t) \approx v(x, t)$ и, если нужно, отдельную сеть $W_\alpha(x, t) \approx R(x, t)$.
5. Сэмплировать $x(T) \sim p(x, T)$ и интегрировать назад:

$$\frac{dx(t)}{dt} = s_\theta(x, t), \quad t : T \rightarrow 0,$$

учитывая branching/birth–death процесс, если $R \neq 0$.

Условия: когда физический процесс становится генеративной моделью

В статье уравнение в частных производных PDE называют ***s*-generative** (*s* от smooth), если выполнены два условия.

- **(C1) Хороший поток плотности.** PDE можно корректно переписать как поток плотности: $p(x, t) \geq 0$, а поля p, v, R не имеют неприемлемых сингулярностей.
- **(C2) Сглаживание.** При $T \rightarrow \infty$ распределение $p(x, T)$ должно становиться асимптотически независимым от исходного p_{data} . Иными словами, forward-динамика должна “забывать” детали данных.

Для линейных PDE условие сглаживания удобно проверять через **дисперсионное соотношение**. Подставим волну

$$\varphi(x, t) \propto \exp(-i\omega t) \exp(ik \cdot x)$$

в PDE и получим зависимость $\omega(k)$. Если высокочастотные моды затухают быстрее низкочастотных, то PDE сглаживает распределение. В статье это формулируется как критерий

$$\text{Im } \omega(k) < \text{Im } \omega(0), \quad k > 0,$$

по крайней мере для одной ветви дисперсионного соотношения. Интуитивно это означает, что пространственные осцилляции с $k > 0$ должны исчезать быстрее, чем нулевая мода, отвечающая общей массе.

Основные примеры

Диффузионные модели

Уравнение диффузии:

$$\varphi_t - \Delta \varphi = p_{\text{data}}(x) \delta(t).$$

Его можно переписать как поток плотности:

$$p = \varphi, \quad v = -\nabla \log \varphi, \quad R = 0.$$

Функция Грина в данном случае имеет вид

$$G(x, t; x') = \frac{1}{(4\pi t)^{N/2}} \exp\left(-\frac{\|x - x'\|^2}{4t}\right),$$

поэтому

$$p(x, t) = \int G(x, t; x') p_{\text{data}}(x') \, d^N x'.$$

Poisson Flow Generative Models

PFGM ([2], [3]) возникает из уравнения Пуассона в расширенном пространстве, где дополнительная координата интерпретируется как время:

$$-(\varphi_{tt} + \Delta\varphi) = p_{\text{data}}(x)\delta(t).$$

Соответствие потоку плотности:

$$p = -\varphi_t, \quad v = \frac{\nabla\varphi}{\varphi_t}, \quad R = 0.$$

Функция Грина имеет степенной вид

$$G(x, t; x') \propto \frac{1}{(t^2 + \|x - x'\|^2)^{(N-1)/2}},$$

а плотность, порожденная полем, ведет себя как

$$p(x, t) \propto \int \frac{t p_{\text{data}}(x')}{(t^2 + \|x - x'\|^2)^{(N+1)/2}} \, d^N x'.$$

Как и диффузия, Poisson-процесс сглаживает данные и дает prior, слабо зависящий от начального распределения при больших T .

*Yukawa / screened Poisson

Новый пример из статьи — screened Poisson, или Yukawa-type GenPhys:

$$\varphi_{tt} + \Delta\varphi - m^2\varphi = 0.$$

Здесь m задает масштаб экранирования: при $m = 0$ возвращается обычное уравнение

Пуассона. Поток плотности:

$$p = -\varphi_t, \quad v = \frac{\nabla \varphi}{\varphi_t}, \quad R = -m^2 \varphi.$$

Функция Грина содержит модифицированную функцию Бесселя K_ν :

$$G(x, t; x') \propto \left(\frac{m}{\sqrt{t^2 + \|x - x'\|^2}} \right)^{(N-1)/2} K_{(N-1)/2} \left(m \sqrt{t^2 + \|x - x'\|^2} \right).$$

Такой процесс похож на Poisson flow, но поле становится более короткодействующим. Авторы считают его полноценным s -generative примером.

Ограничения

Идеальное волновое уравнение

$$\varphi_{tt} - \Delta \varphi = 0$$

не является s -generative: волновой фронт переносит информацию без сглаживания, а поле скорости может иметь сингулярности на фронте. Уравнение Шрёдингера

$$i\varphi_t + \Delta \varphi = 0$$

тоже не подходит в базовом виде. Хотя можно записать

$$p = |\varphi|^2, \quad v = 2 \operatorname{Im} \nabla \log \varphi, \quad R = 0,$$

интерференция может создавать нули p , где скорость становится сингулярной, а осцилляции не исчезают при больших временах. Диссипативная волна и Helmholtz PDE занимают промежуточное положение: при подходящих параметрах они могут вести себя как сглаживающие процессы, но не являются безусловно корректными GenPhys.

PDE	Дисперсия $\omega(k)$	Статус
$\varphi_t - \Delta \varphi = 0$	$-ik^2$	да
$\varphi_{tt} + \Delta \varphi = 0$	$\pm ik$	да, ветвь $-ik$
$\varphi_{tt} - \Delta \varphi = 0$	$\pm k$	нет
$\varphi_{tt} + \Delta \varphi - m^2 \varphi = 0$	$\pm i\sqrt{k^2 + m^2}$	да
$i\varphi_t + \Delta \varphi = 0$	k^2	нет

Вывод

Таким образом, GenPhys — не новая конкретная архитектура, а способ проектирования генеративных моделей. Если физическое PDE можно переписать как корректный поток плотности и оно сглаживает высокочастотные детали, то обратный процесс можно использовать для генерации данных. В эту рамку попадают уже известные диффузионные модели и PFGM, а также новые кандидаты, например Yukawa GenPhys.

Ограничение работы в том, что статья в основном строит теоретическое пространство моделей. Практический вопрос — могут ли новые GenPhys превзойти диффузионные модели или PFGM по качеству, устойчивости и скорости генерации — остается открытым. Тем не менее GenPhys полезен как систематический способ искать новые generative flows не только в машинном обучении, но и в хорошо изученных уравнениях физики.

4.2 Генеративные модели PFGM, EFM and IFM

4.3 Потенциал Юкавы

5 Генеративная модель на основе потенциала Юкавы

6 Результаты вычислительных экспериментов

7 Результаты

Список литературы

1. Genphys: From physical processes to generative models / Z. Liu [и др.] // arXiv preprint arXiv:2304.02637. — 2023.
2. Poisson flow generative models / Y. Xu [и др.] // Advances in Neural Information Processing Systems. — 2022. — Т. 35. — С. 16782—16795.
3. Pfgm++: Unlocking the potential of physics-inspired generative models / Y. Xu [и др.] // International Conference on Machine Learning. — PMLR. 2023. — С. 38566—38591.